MINI-TRANSFORMER + RAG

Bilan de travail — 9 octobre 2026

Ce document récapitule les notions étudiées et le code développé autour de RoPE et du mécanisme d'attention à une seule tête.

Composant	État en fin de séance
Préparation du texte	Réalisée précédemment : corpus, tokenisation, vocabulaire, IDs, tenseurs et embeddings.
RoPE	Formule de rotation corrigée et séparation des dimensions paires/impaires.
Attention simple	Projections Q, K, V, scores, softmax et combinaison pondérée présents dans la classe partagée.
Masques / intégration	Concepts expliqués ; vérifier que RoPE, le masque causal et le masque de padding sont intégrés et testés dans le code final.

1. Rappel : préparer le texte

Un Transformer ne calcule pas directement sur les mots écrits. Le pipeline déjà réalisé est : corpus brut → tokens → vocabulaire → IDs → tenseurs → embeddings. La couche `nn.Embedding` associe à chaque ID un vecteur de dimension `d_model`.

Par exemple, trois tokens avec `d_model = 64` donnent une matrice X de forme `(3, 64)`. Pour un batch de deux séquences de dix positions, la forme est `(2, 10, 64)`.

2. RoPE : encodage positionnel rotatif

RoPE (Rotary Positional Embedding) introduit l'information de position en faisant tourner des paires de composantes. Pour une paire (x_1, x_2) et un angle θ :

$$x_1' = x_1 \cos(\theta) - x_2 \sin(\theta)$$
$$x_2' = x_1 \sin(\theta) + x_2 \cos(\theta)$$

Une erreur dans la première version consistait à extraire deux fois les dimensions paires. La correction est `x[:, 0::2]` pour les composantes paires et `x[:, 1::2]` pour les impaires. Le signe de la seconde équation a aussi été corrigé : le deuxième terme est additionné.

Intégration dans le Transformer : dans l'architecture RoPE standard, on calcule d'abord Q et K par projections linéaires, puis on applique RoPE à Q et K avant le produit QK^T. V n'est généralement pas roté. La fonction initiale accepte une matrice (seq_len, d_k) ; elle doit être adaptée ou appelée par séquence pour gérer (batch_size, seq_len, d_k).

3. Attention à une seule tête : Q, K et V

La classe `Attention(nn.Module)` définit trois projections linéaires apprenables, calculées à partir de la même entrée X :

$$Q = XW_Q \quad K = XW_K \quad V = XW_V$$

Query (Q) : représente ce qu'un token cherche. Key (K) : sert à évaluer la pertinence des autres tokens. Value (V) : porte l'information qui sera combinée pour produire la sortie. Comme Q, K et V proviennent de X, il s'agit de self-attention.

3.1. Scores d'attention

Les scores mesurent la compatibilité entre chaque Query et chaque Key :

$$S = QK^T / \sqrt{d_k}$$

La division par $\sqrt{d_k}$, appelée mise à l'échelle (scaled dot-product attention), évite que les scores deviennent trop grands quand la dimension augmente. Pour une séquence de longueur L, la matrice des scores a la forme (L, L) par élément du batch.

3.2. Softmax

L'application de `F.softmax(scores, dim=-1)` transforme chaque ligne de scores en poids d'attention. Les poids sont entre 0 et 1 et leur somme vaut 1, tant qu'au moins une position reste autorisée.

3.3. Combinaison pondérée des valeurs

La sortie est calculée par O = A V, où A contient les poids d'attention. Il s'agit bien d'un produit matriciel : chaque vecteur V est multiplié par le poids qui lui correspond, puis les contributions sont additionnées. Le résultat est donc une combinaison pondérée de l'information des tokens.

4. Dimensions des tenseurs

Élément	Forme	Rôle
X	(B, L, d_model)	Embeddings d'entrée
Q et K	(B, L, d_k)	Requêtes et clés projetées
V	(B, L, d_v)	Valeurs projetées
Scores / A	(B, L, L)	Scores puis poids entre positions
O	(B, L, d_v)	Sortie de l'attention

B = taille du batch ; L = longueur de la séquence ; d_model = dimension des embeddings ; d_k = dimension des Query/Key ; d_v = dimension des Value. Dans l'exemple étudié, d_model = d_k = d_v = 64.

5. Longueur de séquence et fenêtre de contexte

La longueur de séquence L est le nombre de tokens présents dans l'entrée actuelle. La fenêtre de contexte est la limite maximale de tokens que le modèle peut traiter. Pour les premiers essais, une longueur cible de 10 peut être utilisée : les séquences plus courtes sont complétées avec <pad> et les plus longues sont tronquées ou découpées.

Le padding nécessite un token spécial et un masque de padding pour distinguer les positions de remplissage du contenu réel. Le masque de padding est différent du masque causal.

6. Attention causale et masque

Pour un modèle autorégressif qui prédit le prochain token, la position i ne doit pas consulter les positions futures j > i. Le masque causal remplace leurs scores par $-\infty$ avant le softmax ; leur poids devient alors nul.

> La classe Attention partagée dans la séance calcule actuellement l'attention sans masque. Le masque causal a été expliqué et un exemple de code a été proposé ; il faut confirmer qu'il est ajouté et testé dans le fichier du projet avant de considérer cette fonctionnalité terminée.

7. État d'avancement et prochaines étapes

Statut	Élément	Prochaine action
Déjà réalisé	Corpus, tokenisation, IDs et embeddings	Conserver un vocabulaire stable et tester encode/decode.
Corrigé	Formules et paires de dimensions RoPE	Tester la rotation sur plusieurs positions.
Implémenté	Projections Q/K/V, scores, softmax, sortie pondérée	Tester les dimensions sur différents batches.
À intégrer	RoPE dans la classe Attention	Adapter RoPE à (B, L, d_k), puis l'appliquer à Q et K.

Statut	Élément	Prochaine action
À vérifier	Masques causal et de padding	Vérifier que les tokens futurs et le padding n’influencent pas les sorties autorisées.
Étape suivante	Multi-Head Attention	Diviser les dimensions en plusieurs têtes et concaténer les sorties.

Conclusion

Le travail du jour a permis de passer de la représentation numérique du texte à une première implémentation de l’attention. Les projections Q, K et V, le calcul des scores, le softmax et la combinaison pondérée des valeurs sont en place dans la classe partagée. La formule de RoPE a été corrigée. La suite consiste à intégrer RoPE dans l’attention, puis à valider le masque causal et le masque de padding avant de construire le Multi-Head Attention.